

# Logistic Regression

Ngoc Hoang Luong

University of Information Technology (UIT), VNU-HCM

May 22, 2023

# Hồi quy logistic


Lưu ý Ngọc Hoàng

Trường Đại học Công nghệ Thông tin (UIT), ĐHQG-HCM

22 Tháng Năm, 2023

# Motivation


- Example: Predicting heart attack (coronary heart disease (chd)) with only one predictor: age.



- For age, we have values ranging from small  $x$ 's to large  $x$ 's.
- For the binary response, there are only 0's and 1's (for better visualization, there are some jitter).
- For  $y_i = 0$ , there are more small values  $x$  than large ones. For  $y_i = 1$ , there are more large values  $x$  than small ones.

# Động lực


- Ví dụ: Dự đoán cơ n đau tim (bệnh mạch vành (chd)) chỉ với một yếu tố dự đoán: tuổi.



- Đối với tuổi, chúng tôi có các giá trị từ  $x$  nhỏ đến  $x$  lớn.
- Đối với phản hồi nhị phân, chỉ có 0 và 1 (để tốt hơn trực quan hóa, có một số jitter).
- Với  $y_i = 0$ , có nhiều giá trị  $x$  nhỏ hơn giá trị lớn. Với  $y_i = 1$ , có nhiều giá trị  $x$  lớn hơn giá trị nhỏ.

# Motivation

- Example: Predicting heart attack (coronary heart disease (chd)) with only one predictor: age.




- The goal is to fit a model that predicts chd from age.

$$\text{chd} = f(\text{age}) + \varepsilon$$

# Động lực

- Ví dụ: Dự đoán cơ n đau tim (bệnh mạch vành (chd)) chỉ với một yếu tố dự đoán: tuổi.



- Mục tiêu là để phù hợp với một mô hình dự đoán chd theo độ tuổi.

$$\text{chd} = f(\text{tuổi}) + \varepsilon$$

# First Approach: Fitting a Line

- We could try to fit a linear model:

$$\hat{y} = b_0 + b_1 x = \mathbf{X} \mathbf{y}$$

where

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}; \quad \mathbf{b} = \begin{pmatrix} b_0 \\ b_1 \end{pmatrix}$$

## Cách tiếp cận đầu tiên: Lắp một dòng


- Chúng ta có thể thử điều chỉnh một mô hình tuyến tính:

$$\hat{y} = b_0 + b_1 x = \mathbf{X} \mathbf{y}$$

ở đây


$$\mathbf{X} = \begin{matrix} 1 \times 1 & \text{—} \\ 1 \times 2 & \text{—} \\ & \vdots \\ & 1 \text{ lần} \end{matrix}; \quad \mathbf{b} = \begin{pmatrix} b_0 \\ b_1 \end{pmatrix}$$

## First Approach: Fitting a Line



- There seems to be some positive relation between age and chd.
- The regression line extends beyond the range  $[0,1]$ , which does not make sense.

## Cách tiếp cận đầu tiên: Lắp một dòng



- Dường như có một số mối quan hệ tích cực giữa tuổi tác và chd.
- Đường hồi quy mở rộng ra ngoài phạm vi  $[0,1]$ , không có lý.

## Second Approach: Harsh Thresholding

- We can set some threshold  $c$  and compare  $\hat{y}_i = b_0 + b_1 x_i$  to  $c$ .

$$\hat{y}_i = \begin{cases} 1 & \text{if } b_0 + b_1 x_i \geq c \\ 0 & \text{if } b_0 + b_1 x_i < c \end{cases}$$

- We can arrange the terms to get:

$$\begin{aligned} \hat{y}_i = \hat{f}(x_i) &= b_0 + b_1 x_i - c = (b_0 - c) + b_1 x_i \\ &= b'_0 + b_1 x_i = \mathbf{b}'^\top \mathbf{x}_i \end{aligned}$$

- By paying attention to the sign of the signal  $\mathbf{b}'^\top \mathbf{x}$ , we can transform our fitted model into:

$$\hat{y} = \text{sign}(\mathbf{b}'^\top \mathbf{x})$$

## Cách tiếp cận thứ hai: Ngưỡng khắc nghiệt

- Chúng ta có thể đặt một số ngưỡng  $c$  và so sánh  $\hat{y}_i = b_0 + b_1 x_i$  với  $c$ .

$$\begin{aligned} &1 \text{ nếu } b_0 + b_1 x_i \geq c \\ \hat{y}_i &= 0 \text{ nếu } b_0 + b_1 x_i < c \end{aligned}$$

- Ta có thể sắp xếp các điều kiện để có được:

$$\begin{aligned} \hat{y}_i = \hat{f}(x_i) &= b_0 + b_1 x_i - c = (b_0 - c) + b_1 x_i \\ &= b'_0 + b_1 x_i = \mathbf{b}'^\top \mathbf{x}_i \end{aligned}$$

- Bằng cách chú ý đến dấu của tín hiệu  $\mathbf{b}'^\top \mathbf{x}$ , chúng ta có thể chuyển đổi mô hình được trang bị của chúng tôi thành:


$$\hat{y} = \text{dấu}(\mathbf{b}'^\top \mathbf{x})$$

## Second Approach: Harsh Thresholding

- We have a classification rule:

$$\hat{y}_i = \begin{cases} 1 & \text{if } \text{sign}(b'_0 + b_1 x_i) \geq 0 \\ 0 & \text{if } \text{sign}(b'_0 + b_1 x_i) < 0 \end{cases}$$

- The signal is still linear but we apply a non-linear transformation to it:  $\phi(x) = \text{sign}(b'_0 + b_1 x_i)$




## Cách tiếp cận thứ hai: Ngưỡng khắc nghiệt

- Ta có quy tắc phân loại:

$$\hat{y}_i = \begin{cases} 1 & \text{nếu dấu}(b'_0 + b_1 x_i) \geq 0 \\ 0 & \text{nếu dấu}(b'_0 + b_1 x_i) < 0 \end{cases}$$

- Tín hiệu vẫn là tuyến tính nhưng chúng tôi áp dụng phép biến đổi phi tuyến cho nó:  $\phi(x) = \text{dấu}(b'_0 + b_1 x_i)$



## Third Approach: Conditional Means

- For example, we consider a patient  $x = 24$  years old, and we count the relative frequency of chd cases. We compute the conditional mean:  $avg(y_i \mid x_i = 24)$
- Similarly, we could compute all conditional means for all age values:

$$(\bar{y} \mid x_i = 25), (\bar{y} \mid x_i = 26), \dots (\bar{y} \mid x_i = 70),$$

- If we do not have data points for a specific  $x$ -value, we can use groups of ages. For example, we compute the proportion of chd cases in the group of ages 20 – 29 years:

$$avg(y_i \mid x_i \in \{20 - 29 \text{ years}\})$$

## Cách tiếp cận thứ ba: Phân phối có điều kiện

- Ví dụ: chúng tôi xem xét một bệnh nhân  $x = 24$  tuổi và chúng tôi tính tần suất tương đối của các trường hợp mắc bệnh chd. Chúng tôi tính giá trị trung bình có điều kiện:  $avg(y_i \mid x_i = 24)$
- Tương tự, chúng ta có thể tính tất cả các phân phối có điều kiện cho tất cả các giá trị tuổi:

$$(\bar{y} \mid x_i = 25), (\bar{y} \mid x_i = 26), \dots (\bar{y} \mid x_i = 70),$$

- Nếu chúng tôi không có điểm dữ liệu cho một giá trị  $x$  cụ thể, chúng tôi có thể sử dụng các nhóm tuổi. Ví dụ: chúng tôi tính tỷ lệ các trường hợp mắc bệnh chd trong nhóm tuổi 20 – 29 tuổi:


$$avg(y_i \mid x_i \in \{20 - 29 \text{ năm}\})$$



## Third Approach: Conditional Means

- For each age group, we calculate the proportion of chd cases:


$$avg(y_i \mid x_i \in \text{age group})$$



## Cách tiếp cận thứ ba: Phươ ng tiện có điều kiện


- Với mỗi nhóm tuổi, chúng tôi tính tỷ lệ mắc bệnh chd:

$$avg(y_i \mid x_i \in \text{nhóm tuổi})$$




## Third Approach: Conditional Means

- Theoretical we are modeling the conditional expectations:  $\mathbb{E}(y | x)$ . This is the regression function.
- Connecting the averages, we have a sigmoid pattern:



## Cách tiếp cận thứ ba: Phức hợp tuyến tính có điều kiện


- Về mặt lý thuyết, chúng tôi đang mô hình hóa các kỳ vọng có điều kiện:  $\mathbb{E}(y | x)$ . Đây là hàm hồi quy.
- Nối các giá trị trung bình, chúng ta có một mẫu sigmoid:



## Third Approach: Conditional Means

- The pattern can be approximated by some mathematical functions.
- The most popular is the **logistic function**:


$$f(s) = \frac{e^s}{1 + e^s} = \frac{1}{1 + e^{-s}}$$



## Cách tiếp cận thứ ba: Phân loại có điều kiện

- Mẫu có thể được tính gần đúng bằng một số hàm toán học.
- Phổ biến nhất là **chức năng logistic**:


$$f(s) = \frac{e^s}{1 + e^s} = \frac{1}{1 + e^{-s}}$$



## Third Approach: Conditional Means

- Replacing the signal  $s$  by a linear model  $\beta_0 + \beta_1 x$ , we have:

$$\hat{f}(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$




- Since probability values range inside  $[0,1]$ , instead of using a line to approximate these values, we should use a more adequate curve.

Cách tiếp cận thứ ba: Phương tiện có điều kiện • Thay tín

hiệu  $s$  bằng mô hình tuyến tính  $\beta_0 + \beta_1 x$ , ta có:

$$f(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$



- Vì các giá trị xác suất nằm trong khoảng  $[0,1]$  nên thay vì sử dụng một đường để tính gần đúng các giá trị này, chúng ta nên sử dụng một đường cong phù hợp hơn.

# Logistic Regression Model

- We consider the model:

$$Prob(y \mid \mathbf{x}; \mathbf{b}) = f(\mathbf{x})$$

- However, we don't observe the true probability  $\in [0, 1]$ . We only observe the noisy targets  $y_i \in \{0, 1\}$  that is generated by the probability  $f(\mathbf{x})$ .
- We model the probability by using a mathematical function that has the sigmoid shape, and the most popular function is the **logistic function**.

$$Prob(y_i \mid \mathbf{x}_i; \mathbf{b}) = \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}}$$

where  $\mathbf{x}_i$  represents the vector of features of individual  $i$ .

## Mô hình hồi quy logistic

- Ta xét mô hình:

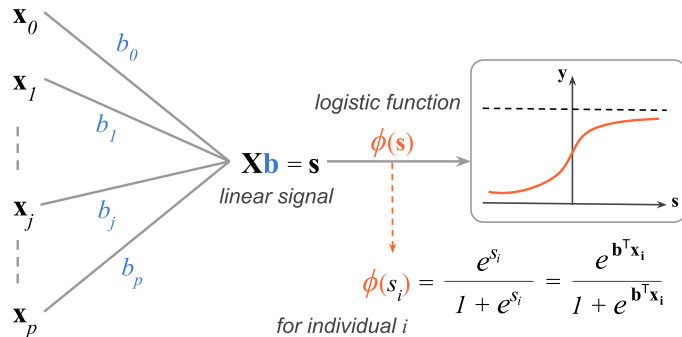
$$P \text{ dự đoán}(y \mid \mathbf{x}; \mathbf{b}) = f(\mathbf{x})$$

- Tuy nhiên, chúng tôi không quan sát thấy xác suất thực  $\in [0, 1]$ . Chúng tôi chỉ quan sát các mục tiêu nhiễu  $y_i \in \{0, 1\}$  được tạo bởi xác suất  $f(\mathbf{x})$ .
- Chúng tôi lập mô hình xác suất bằng cách sử dụng hàm toán học có dạng sigmoid và hàm phổ biến nhất là **hàm logistic**.

$$P \text{ dự đoán}(y_i \mid \mathbf{x}_i; \mathbf{b}) = \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}}$$

trong đó  $\mathbf{x}_i$  đại diện cho vectơ đặc trưng của cá nhân  $i$ .

# Logistic Regression Model

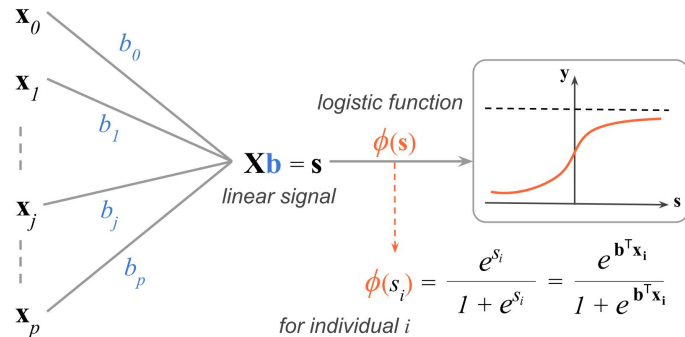


$$Prob(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{for } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{for } y_i = 0 \end{cases}$$

where  $h()$  denotes the logistic function  $\phi()$ :

$$h(\mathbf{x}) = \phi(\mathbf{b}^T \mathbf{x})$$

# Mô hình hồi quy logistic



$$P \text{ cư ớp}(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{với } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{với } y_i = 0 \end{cases}$$

trong đó  $h()$  biểu thị hàm logistic  $\phi()$ :  $h(\mathbf{x}) = \phi(\mathbf{b}^T \mathbf{x})$

$\mathbf{x})$

# The Criterion Being Optimized

$$Prob(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{for } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{for } y_i = 0 \end{cases}$$

- Assuming that our model is true, i.e.,  $h(x) = f(x)$ , we ask “how likely is it that we observe the data we already observed ( $y_i$ )?”

$$\begin{aligned} Prob(\mathbf{y} | x_1, x_2, \dots, x_p; \mathbf{b}) &= \prod_{i=1}^n P(y_i | \mathbf{b}^\top \mathbf{x}_i) \\ &= \prod_{i=1}^n h(\mathbf{b}^\top \mathbf{x}_i)^{y_i} [1 - h(\mathbf{b}^\top \mathbf{x}_i)]^{1-y_i} \end{aligned}$$

# Tiêu chí đư ợc tối ư u hóa

$$P \text{ c ư Ớp}(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{v ớ i } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{v ớ i } y_i = 0 \end{cases}$$

- Giả sử rằng mô hình của chúng ta là đúng, tức là  $h(x) = f(x)$ , chúng ta hỏi “khả năng chúng ta quan sát dữ liệu mà chúng ta đã quan sát ( $y_i$ ) là bao nhiêu?”

$$\begin{aligned} P \text{ c ư Ớp}(\mathbf{y} | x_1, x_2, \dots, x_p; \mathbf{b}) &= \prod_{i=1}^n P(y_i | \mathbf{b}^\top \mathbf{x}_i) \\ &= \prod_{i=1}^n h(\mathbf{b}^\top \mathbf{x}_i)^{y_i} [1 - h(\mathbf{b}^\top \mathbf{x}_i)]^{1-y_i} \end{aligned}$$

# The Criterion Being Optimized

- Take the logarithm (log-likelihood)

$$\begin{aligned}l(\mathbf{b}) &= \ln [L(\mathbf{b})] \\&= \sum_{i=1}^n \ln [P(y_i | \mathbf{b}^\top \mathbf{x}_i)] \\&= \sum_{i=1}^n \{y_i \ln [h(\mathbf{b}^\top \mathbf{x}_i)] + (1 - y_i) \ln [1 - h(\mathbf{b}^\top \mathbf{x}_i)]\} \\&= \sum_{i=1}^n \left[ y_i \ln \left( \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} \right) + (1 - y_i) \ln \left( 1 - \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} \right) \right] \\&= \sum_{i=1}^n \left[ y_i \mathbf{b}^\top \mathbf{x}_i - \ln (1 + e^{\mathbf{b}^\top \mathbf{x}_i}) \right]\end{aligned}$$

- Differentiating and setting to 0 yields an equation for which no closed-form solution exists.

# Tiêu chí được tối ưu hóa

- Lấy logarit (log-likelihood)

$$\begin{aligned}l(\mathbf{b}) &= \ln [L(\mathbf{b})] \\&= \sum_{i=1}^N \ln [P(y_i | \mathbf{b}^\top \mathbf{x}_i)] \\&= \sum_{i=1}^N \{y_i \ln [h(\mathbf{b}^\top \mathbf{x}_i)] + (1 - y_i) \ln [1 - h(\mathbf{b}^\top \mathbf{x}_i)]\} \\&= \sum_{i=1}^N \left[ y_i \ln \left( \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} \right) + (1 - y_i) \ln \left( 1 - \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} \right) \right] \\&= \sum_{i=1}^N \left[ y_i \mathbf{b}^\top \mathbf{x}_i - \ln (1 + e^{\mathbf{b}^\top \mathbf{x}_i}) \right]\end{aligned}$$

- Vi phân và đặt thành 0 sẽ tạo ra một phương trình không tồn tại nghiệm dạng đóng.



# The Criterion Being Optimized

- We need to use **gradient ascent**.
- The gradient of the likelihood function is:

$$\begin{aligned}\nabla l(\mathbf{b}) &= \sum_{i=1}^n \left[ y_i \mathbf{x}_i - \left( \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} \right) \mathbf{x}_i \right] \\ &= \sum_{i=1}^n [y_i \mathbf{x}_i - \phi(\mathbf{b}^\top \mathbf{x}_i) \mathbf{x}_i] \\ &= \sum_{i=1}^n [y_i - \phi(\mathbf{b}^\top \mathbf{x}_i)] \mathbf{x}_i\end{aligned}$$

- In gradient ascent, we would update the parameters  $\mathbf{b}$ :

$$\mathbf{b}^{(s+1)} = \mathbf{b}^{(s)} + \alpha \nabla l(\mathbf{b}^{(s)})$$

# Tiêu chí đư ợc tối ư u hóa

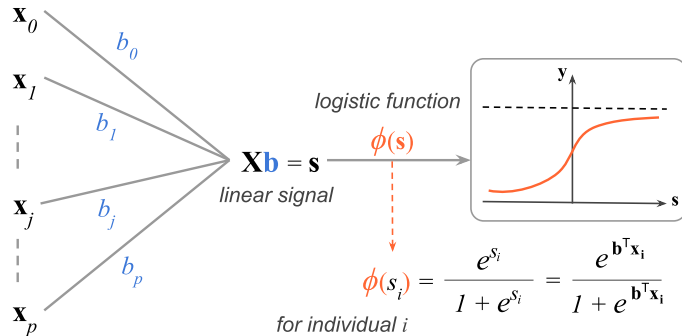
- Chúng ta cần sử dụng **độ dốc tăng dần**.
- Độ dốc của hàm khả năng là:

$$\begin{aligned}l(\mathbf{b}) &= \sum_{i=1}^N [y_i x_i - \frac{e^{\mathbf{b}^\top \mathbf{x}_i}}{1 + e^{\mathbf{b}^\top \mathbf{x}_i}} x_i] \\ &= \sum_{i=1}^N [y_i x_i - \phi(\mathbf{b}^\top \mathbf{x}_i) x_i] \\ &= \sum_{i=1}^N [y_i - \phi(\mathbf{b}^\top \mathbf{x}_i)] x_i\end{aligned}$$

- Khi tăng dần độ dốc, chúng tôi sẽ cập nhật các tham số  $\mathbf{b}$ :

$$\mathbf{b}^{(s+1)} = \mathbf{b}^{(s)} + \alpha \nabla l(\mathbf{b}^{(s)})$$

## Another Way to Solve Logistic Regression

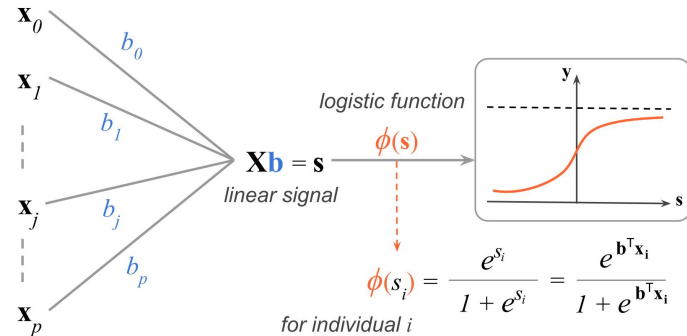


What it used to be  $y_i = 0$ , let's encode it as  $y_i = -1$

$$Prob(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{for } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{for } y_i = -1 \end{cases}$$

where  $h()$  denotes the logistic function  $\phi()$ :  $h(\mathbf{x}) = \phi(\mathbf{b}^T \mathbf{x})$

## Một cách khác để giải quyết hồi quy logistic



Nó từng là  $y_i = 0$ , hãy mã hóa nó thành  $y_i = 1$

$$P \text{ dự đoán}(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & \text{với } y_i = 1 \\ 1 - h(\mathbf{x}_i) & \text{với } y_i = -1 \end{cases}$$

trong đó  $h()$  biểu thị hàm logistic  $\phi()$ :  $h(\mathbf{x}) = \phi(\mathbf{b}^T \mathbf{x})$

## Another Way to Solve Logistic Regression

- The logistic function has the property:

$$\phi(-s) = \frac{e^{-s}}{1 + e^{-s}} = \frac{1 - 1 + e^{-s}}{1 + e^{-s}} = 1 - \frac{1}{1 + e^{-s}} = 1 - \phi(s)$$

- We can update the expression for the conditional probability:

$$Prob(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) & = \phi(y_i \mathbf{b}^\top \mathbf{x}) \text{ for } y_i = 1 \\ 1 - h(\mathbf{x}_i) & = \phi(y_i \mathbf{b}^\top \mathbf{x}) \text{ for } y_i = -1 \end{cases}$$

- This implies that we only need one case regardless of  $y_i$ :

$$Prob(y_i | \mathbf{x}_i; \mathbf{b}) = \phi(y_i \mathbf{b}^\top \mathbf{x})$$

## Một cách khác để giải quyết hồi quy logistic

- Hàm hậu cần có thuộc tính:

$$\varphi(-s) = \frac{e^{-s}}{1 + e^{-s}} = \frac{1 - 1 + e^{-s}}{1 + e^{-s}} = 1 - \frac{1}{1 + e^{-s}} = 1 - \varphi(s)$$

- Chúng ta có thể cập nhật biểu thức cho xác suất có điều kiện:

$$P \text{ dự đoán}(y_i | \mathbf{x}_i; \mathbf{b}) = \begin{cases} h(\mathbf{x}_i) = \varphi(y_i \mathbf{b}^\top \mathbf{x}) \text{ với } y_i = 1 \\ 1 - h(\mathbf{x}_i) = \varphi(y_i \mathbf{b}^\top \mathbf{x}) \text{ với } y_i = -1 \end{cases}$$

- Điều này ngụ ý rằng chúng ta chỉ cần một trường hợp bất kể  $y_i$ :

$$P \text{ dự đoán}(y_i | \mathbf{x}_i; \mathbf{b}) = \varphi(y_i \mathbf{b}^\top \mathbf{x})$$

## Another Way to Solve Logistic Regression

- We can compute the likelihood as previously:

$$\begin{aligned} \text{Prob}(\mathbf{y} \mid x_1, x_2, \dots, x_p; \mathbf{b}) &= \prod_{i=1}^n P(y_i \mid \mathbf{b}^\top \mathbf{x}_i) \\ &= \prod_{i=1}^n \phi(y_i \mathbf{b}^\top \mathbf{x}_i) \end{aligned}$$

- then log-likelihood:

$$\begin{aligned} l(\mathbf{b}) &= \ln [L(\mathbf{b})] = \sum_{i=1}^n \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \\ &\Rightarrow \frac{1}{n} \sum_{i=1}^n \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \end{aligned}$$

- Instead of maximizing the log-likelihood, we can minimize the negative log-likelihood

$$\min_{\mathbf{b}} \left\{ -\frac{1}{n} \sum_{i=1}^n \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\}$$

Một cách khác để giải quyết hồi quy logistic • Chúng ta có

thể tính toán khả năng xảy ra như trước đây:

$$\begin{aligned} P \text{ của } (y_1, x_1, x_2, \dots, x_p; \mathbf{b}) &= \prod_{i=1}^N P(y_i \mid \mathbf{b}^\top \mathbf{x}_i) \\ &= \prod_{i=1}^N \phi(y_i \mathbf{b}^\top \mathbf{x}_i) \end{aligned}$$

- thì log-likelihood:

$$\begin{aligned} l(\mathbf{b}) &= \ln [L(\mathbf{b})] = \sum_{i=1}^N \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \\ &= \frac{1}{N} \sum_{i=1}^N \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \end{aligned}$$

- Thay vì tối đa hóa khả năng đăng nhập, chúng ta có thể giảm thiểu khả năng đăng nhập tiêu cực

$$\min_{\mathbf{b}} \left\{ -\frac{1}{N} \sum_{i=1}^N \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\}$$

## Another Way to Solve Logistic Regression

$$\min_{\mathbf{b}} \left\{ -\frac{1}{n} \sum_{i=1}^n \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\} \Leftrightarrow \min_{\mathbf{b}} \left\{ \underbrace{\frac{1}{n} \sum_{i=1}^n \ln (1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i})}_{\substack{\text{pointwise error} \\ E_{in}(\mathbf{b})}} \right\}$$

- Focus on the product term between the response and the linear signal:  $y_i \mathbf{b}^\top \mathbf{x}_i = y_i s$  where  $s$  represents “signal”.
- A small signal means that the probability  $\phi(\mathbf{b}^\top \mathbf{x}_i)$  will be small.
- A large signal means that the probability  $\phi(\mathbf{b}^\top \mathbf{x}_i)$  will be large.
- The term  $y_i$  can be either -1 or +1.

## Một cách khác để giải quyết hồi quy logistic

$$\min_{\mathbf{b}} \left\{ -\frac{1}{n} \sum_{i=1}^N \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\} \Leftrightarrow \min_{\mathbf{b}} \left\{ \underbrace{\frac{1}{n} \sum_{i=1}^N \ln (1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i})}_{\substack{\text{pointwise error} \\ E_{in}(\mathbf{b})}} \right\}$$

- Tập trung vào thuật ngữ tích giữa phản hồi và tín hiệu tuyến tính:  $y_i \mathbf{b}^\top \mathbf{x}_i = y_i s$  trong đó  $s$  đại diện cho “tín hiệu”.
- Tín hiệu nhỏ nghĩa là xác suất  $\phi(\mathbf{b}^\top \mathbf{x}_i)$  sẽ nhỏ.
- Tín hiệu lớn có nghĩa là xác suất  $\phi(\mathbf{b}^\top \mathbf{x}_i)$  sẽ lớn.
- Số hạng  $y_i$  có thể là -1 hoặc +1.

## Another Way to Solve Logistic Regression

$$\min_{\mathbf{b}} \left\{ -\frac{1}{n} \sum_{i=1}^n \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\} \Leftrightarrow \min_{\mathbf{b}} \left\{ \underbrace{\frac{1}{n} \sum_{i=1}^n \ln (1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i})}_{\text{cross-entropy error}} \right\}$$

$E_{in}(\mathbf{b})$

- With correct predictions,  $e^{-y_i \mathbf{b}^\top \mathbf{x}_i}$  will be small, and will give a small error.
- With incorrect predictions,  $e^{-y_i \mathbf{b}^\top \mathbf{x}_i}$  will be large, and will give a large error.
- We need to find  $\mathbf{b}$  to minimize  $E_{in}(\mathbf{b})$ . We need to use **gradient descent** with the gradient w.r.t.  $\mathbf{b}$  can be computed as:

$$\nabla E_{in}(\mathbf{b}) = -\frac{1}{n} \sum_{i=1}^n \left( \frac{e^{-y_i \mathbf{b}^\top \mathbf{x}_i}}{1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i}} \right) y_i \mathbf{x}_i = -\frac{1}{n} \sum_{i=1}^n \left( \frac{1}{1 + e^{y_i \mathbf{b}^\top \mathbf{x}_i}} \right) y_i \mathbf{x}_i$$

## Một cách khác để giải quyết hồi quy logistic

$$\min_{\mathbf{b}} \left\{ \frac{1}{N} \sum_{i=1}^N \ln [\phi(y_i \mathbf{b}^\top \mathbf{x}_i)] \right\} \Leftrightarrow \min_{\mathbf{b}} \left\{ \underbrace{\frac{1}{N} \sum_{i=1}^N \ln (1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i})}_{\text{lỗi entropy chéo}} \right\}$$

$E_{in}(\mathbf{b})$

Với dự đoán đúng,  $e^{-y_i \mathbf{b}^\top \mathbf{x}_i}$  sẽ nhỏ và sẽ cho số nhỏ.

đ đoán sai,  $e^{-y_i \mathbf{b}^\top \mathbf{x}_i}$  sẽ lớn và sẽ cho kết quả lớn.

- Ta cần tìm  $\mathbf{b}$  để  $E_{in}(\mathbf{b})$  nhỏ nhất. Chúng ta cần sử dụng **giảm độ dốc** với độ dốc wrt  $\mathbf{b}$  có thể được tính như sau:

$$E_{in}(\mathbf{b}) = \frac{1}{N} \sum_{i=1}^N \ln (1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i})$$

$$\nabla E_{in}(\mathbf{b}) = \frac{1}{N} \sum_{i=1}^N \left( \frac{-y_i \mathbf{x}_i}{1 + e^{-y_i \mathbf{b}^\top \mathbf{x}_i}} \right) = -\frac{1}{N} \sum_{i=1}^N \left( \frac{y_i \mathbf{x}_i}{1 + e^{y_i \mathbf{b}^\top \mathbf{x}_i}} \right)$$