

Regularizations

Ngoc Hoang Luong

University of Information Technology (UIT), VNU-HCM

April 13, 2023

Chính quy hóa

Lương Ngọc Hoàng

Trường Đại học Công nghệ Thông tin (UIT), ĐHQG-HCM

Ngày 13 tháng 4 năm 2023

Linear Regression

- In **linear regression**, the overall error function $E()$ is the mean squared error (MSE).

Machine Translated by Google

Hồi quy tuyến tính •

Trong **hồi quy tuyến tính**, hàm lỗi tổng thể $E()$ là lỗi bình phương trung bình (MSE).

Linear Regression

- In **linear regression**, the overall error function $E()$ is the mean squared error (MSE).
- From the perspective of the parameters (i.e., the regression coefficients), we denote the error function as $E(\mathbf{b})$.

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{Xb} - \mathbf{y})^T(\mathbf{Xb} - \mathbf{y})$$

Hồi quy tuyến tính •

Trong **hồi quy tuyến tính**, hàm lỗi tổng thể $E()$ là lỗi bình phương trung bình (MSE).

- Từ quan điểm của các tham số (nghĩa là các hệ số hồi quy), chúng ta ký hiệu hàm sai số là $E(\mathbf{b})$.


$$E(\mathbf{b}) = \frac{1}{N}(\mathbf{Xb} - \mathbf{y})^T(\mathbf{Xb} - \mathbf{y})$$

Linear Regression

- In **linear regression**, the overall error function $E()$ is the mean squared error (MSE).
- From the perspective of the parameters (i.e., the regression coefficients), we denote the error function as $E(\mathbf{b})$.

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top(\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Let's consider two inputs X_1 and X_2 , and their corresponding parameters b_1 and b_2 . The error function $E(\mathbf{b})$ generates a convex error surface with the shape of a bowl (or a paraboloid).




Hồi quy tuyến tính •

Trong **hồi quy tuyến tính**, hàm lỗi tổng thể $E()$ là lỗi bình phương trung bình (MSE).

- Từ quan điểm của các tham số (nghĩa là các hệ số hồi quy), chúng ta ký hiệu hàm sai số là $E(\mathbf{b})$.

$$E(\mathbf{b}) = \frac{1}{N}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top(\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Hãy xem xét hai đầu vào X_1 và X_2 và tương ứng của chúng thông số b_1 và b_2 . Hàm lỗi $E(\mathbf{b})$ tạo ra một bề mặt lỗi lồi với hình dạng của một cái bát (hoặc một paraboloid).



Linear Regression

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- In ordinary least squares (OLS), we minimize $E(\mathbf{b})$ **unconditionally**: without any restriction.

hồi quy tuyến tính


$$E(\mathbf{b}) = \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Trong bình phương nhỏ nhất thông thường (OLS), chúng ta tối thiểu hóa $E(\mathbf{b})$ **một cách vô điều kiện**: không có bất kỳ hạn chế nào.

Linear Regression

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$


- In ordinary least squares (OLS), we minimize $E(\mathbf{b})$ **unconditionally**: without any restriction.
- The solution is indicated with a **blue dot** at the center of the elliptical contours of constant error.



hồi quy tuyến tính

$$E(\mathbf{b}) = \frac{1}{N}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Trong bình phương nhỏ nhất thông thường (OLS), chúng ta tối thiểu hóa $E(\mathbf{b})$ **một cách vô điều kiện**: không có bất kỳ hạn chế nào.
- Dung dịch được biểu thị bằng một **chấm màu xanh lam** ở giữa đường viền elip của lỗi liên tục.



Linear Regression - Constraining Regression Coefficients

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- We would like now to impose a restriction on the squared magnitude of the regression coefficients.

Hồi quy tuyến tính - Hệ số hồi quy ràng buộc

$$E(\mathbf{b}) = \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$


- Bây giờ chúng tôi muốn áp đặt một hạn chế đối với bình phương độ lớn của các hệ số hồi quy.

Linear Regression - Constraining Regression Coefficients

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- We would like now to impose a restriction on the squared magnitude of the regression coefficients.
- We still minimize $E(\mathbf{b})$, but now we require the following condition on b_1, b_2, \dots, b_p :

$$\sum_{j=1}^p b_j^2 \leq c \quad (1)$$




Hồi quy tuyến tính - Hệ số hồi quy ràng buộc

$$E(\mathbf{b}) = \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Bây giờ chúng tôi muốn áp đặt một hạn chế đối với bình phương độ lớn của các hệ số hồi quy.
- Ta vẫn giảm thiểu $E(\mathbf{b})$, nhưng bây giờ ta cần điều kiện sau trên b_1, b_2, \dots, b_p :

$$\sum_{j=1}^p b_j^2 \leq c \quad (1)$$




Linear Regression - Constraining Regression Coefficients

$$E(\mathbf{b}) = \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- We have a constrained minimization of $E(\mathbf{b})$ for some “budget” c :

$$\min_{\mathbf{b}} \left\{ \frac{1}{n}(\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$




Hồi quy tuyến tính - Hệ số hồi quy ràng buộc

$$E(\mathbf{b}) = \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y})$$

- Chúng tôi có mức tối thiểu hóa hạn chế của $E(\mathbf{b})$ đối với một số “ngân sách” c :


$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$



Linear Regression - Constraining Regression Coefficients

$$\min_{\mathbf{b}} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$


- If we choose too big values of c , we could have a big enough constraint that includes the OLS solution.



Hồi quy tuyến tính - Hệ số hồi quy ràng buộc

$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$


- Nếu chúng ta chọn giá trị c quá lớn, chúng ta có thể có một ràng buộc bao gồm giải pháp OLS.



Linear Regression - Constraining Regression Coefficients

$$\min_{\mathbf{b}} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$


- We could make the budget stricter by reducing the value of c



Hồi quy tuyến tính - Hệ số hồi quy ràng buộc


$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

- Chúng ta có thể thắt chặt ngân sách hơn bằng cách giảm giá trị của c




Linear Regression - A New Minimization Solution

- Let's consider one elliptical contour of constant error, a given budget c , and a point \mathbf{b} satisfying the budget constraint




Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

- Hãy xem xét một đường bao hình elip có sai số không đổi, ngân sách c cho trước và điểm \mathbf{b} thỏa mãn giới hạn ngân sách



Linear Regression - A New Minimization Solution


- Let's consider one elliptical contour of constant error, a given budget c , and a point \mathbf{b} satisfying the budget constraint



- $\mathbf{b}^T \mathbf{b} = c$. However, this point does not fully minimize $E(\mathbf{b})$.

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới


- Hãy xem xét một đường bao hình elip có sai số không đổi, ngân sách c cho trước và điểm \mathbf{b} thỏa mãn giới hạn ngân sách



- $\mathbf{b}^T \mathbf{b} = c$. Tuy nhiên, điểm này không giảm thiểu hoàn toàn $E(\mathbf{b})$.

Linear Regression - A New Minimization Solution


- Let's consider one elliptical contour of constant error, a given budget c , and a point \mathbf{b} satisfying the budget constraint



- $\mathbf{b}^T \mathbf{b} = c$. However, this point does not fully minimize $E(\mathbf{b})$.
- We could still find other \mathbf{b} along the **circle** that would give us smaller $E(\mathbf{b})$.


Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

- Hãy xem xét một đường bao hình elip có sai số không đổi, ngân sách c cho trước và điểm \mathbf{b} thỏa mãn giới hạn ngân sách




- $\mathbf{b}^T \mathbf{b} = c$. Tuy nhiên, điểm này không giảm thiểu hoàn toàn $E(\mathbf{b})$.
- Chúng tôi vẫn có thể tìm thấy các \mathbf{b} khác dọc theo **vòng tròn** sẽ cho chúng tôi $E(\mathbf{b})$ nhỏ hơn.

Linear Regression - A New Minimization Solution




- The gradient $\nabla E(\mathbf{b})$ points in the direction orthogonal to the contour ellipse, i.e., the direction of largest change of $E(\mathbf{b})$.

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới




- Độ dốc $E(\mathbf{b})$ chỉ theo hướng trực giao với đường bao elip, tức là hướng thay đổi lớn nhất của $E(\mathbf{b})$.

Linear Regression - A New Minimization Solution




- The gradient $\nabla E(\mathbf{b})$ points in the direction orthogonal to the contour ellipse, i.e., the direction of largest change of $E(\mathbf{b})$.
- The direction of \mathbf{b} is orthogonal to the circumference of the constraint (normal vector). The angle between the gradient and the normal vector is less than 180 degrees. We can find better \mathbf{b} points that make the error smaller. Where is that optimal \mathbf{b}^* ?

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới




- Độ dốc $E(\mathbf{b})$ chỉ theo hướng trực giao với đường bao elip, tức là hướng thay đổi lớn nhất của $E(\mathbf{b})$.
- Hướng của \mathbf{b} là trực giao với chu vi của ràng buộc (vector pháp tuyến). Góc giữa gradient và vector pháp tuyến nhỏ hơn 180 độ. Chúng ta có thể tìm thấy điểm \mathbf{b} tốt hơn làm cho sai số nhỏ hơn. Đó là tối ưu ở đâu \mathbf{b}^* ?

Linear Regression - A New Minimization Solution




- The optimal vector \mathbf{b}^* corresponds to the one that is exactly the opposite of $\nabla E(\mathbf{b})$. The gradient and the normal vectors are anti-parallel: $\nabla E(\mathbf{b}^*) \propto -\mathbf{b}^*$.

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới



- Vectơ \mathbf{b} tối ưu đối của $\nabla E(\mathbf{b})$ tương ứng với một trong đó là chính xác \mathbf{b}^* . Độ dốc và các vectơ pháp tuyến là phản song song: $\nabla E(\mathbf{b}^*) \propto -\mathbf{b}^*$.


Linear Regression - A New Minimization Solution



- The optimal vector \mathbf{b}^* corresponds to the one that is exactly the opposite of $\nabla E(\mathbf{b})$. The gradient and the normal vectors are anti-parallel: $\nabla E(\mathbf{b}^*) \propto -\mathbf{b}^*$.
- We choose a proportionality constant of $-2(\lambda/n)$

$$\nabla E(\mathbf{b}^*) = -2\frac{\lambda}{n}\mathbf{b}^*$$

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới



- Vectơ \mathbf{b} tối ưu đối tượng tương ứng với một trong đó là chính xác của $E(\mathbf{b})$. Độ dốc và các vectơ pháp tuyến là phản song song: $\nabla E(\mathbf{b}^*) \propto -\mathbf{b}^*$.
- Chúng tôi chọn hằng số tỷ lệ là $-2(\lambda/n)$

$$E(\mathbf{b}) = \frac{\lambda}{2N} \|\mathbf{b}\|^2$$

Linear Regression - A New Minimization Solution

$$\nabla E(\mathbf{b}^*) = -2\frac{\lambda}{n}\mathbf{b}^*$$

$$\nabla E(\mathbf{b}^*) + 2\frac{\lambda}{n}\mathbf{b}^* = \mathbf{0}$$

- The above expression is the gradient of the following function:

$$f(\mathbf{b}) = E(\mathbf{b}) + \frac{\lambda}{n}\mathbf{b}^\top \mathbf{b}$$

$$\nabla f(\mathbf{b}^*) = \nabla E(\mathbf{b}^*) + 2\frac{\lambda}{n}\mathbf{b}^*$$

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

$$E(\mathbf{b} \quad \lambda) = \frac{1}{N}\mathbf{b}^\top \mathbf{b}$$

$$E(\mathbf{b} \quad \lambda) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b} = 0$$

- Biểu thức trên là gradient của hàm sau:

$$f(\mathbf{b}) = E(\mathbf{b}) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b}$$

$$f(\mathbf{b} \quad \lambda) = E(\mathbf{b} \quad \lambda) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b}$$

Linear Regression - A New Minimization Solution

$$\nabla E(\mathbf{b}^*) = -2\frac{\lambda}{n}\mathbf{b}^*$$

$$\nabla E(\mathbf{b}^*) + 2\frac{\lambda}{n}\mathbf{b}^* = \mathbf{0}$$

- The above expression is the gradient of the following function:

$$f(\mathbf{b}) = E(\mathbf{b}) + \frac{\lambda}{n}\mathbf{b}^\top \mathbf{b}$$

$$\nabla f(\mathbf{b}^*) = \nabla E(\mathbf{b}^*) + 2\frac{\lambda}{n}\mathbf{b}^*$$

- Now, our minimization problem becomes:

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{n}\mathbf{b}^\top \mathbf{b} \right\}$$

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

$$E(\mathbf{b} \quad \lambda) = \frac{1}{N}\mathbf{b}^\top \mathbf{b}$$

$$E(\mathbf{b} \quad \lambda) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b} = 0$$

- Biểu thức trên là gradient của hàm sau:

$$f(\mathbf{b}) = E(\mathbf{b}) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b}$$

$$f(\mathbf{b} \quad \lambda) = E(\mathbf{b} \quad \lambda) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b}$$

- Bây giờ, bài toán tối thiểu hóa của chúng ta trở thành:

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{N}\mathbf{b}^\top \mathbf{b} \right\}$$

Linear Regression - A New Minimization Solution

$$\begin{aligned} f(\mathbf{b}) &= E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} = \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \\ &= \frac{1}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{y} + \frac{1}{n} \mathbf{y}^\top \mathbf{y} + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \end{aligned}$$

- Compute the gradient:

$$\nabla f(\mathbf{b}) = \frac{2}{n} \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{X}^\top \mathbf{y} + \frac{2\lambda}{n} \mathbf{b}$$

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

$$\begin{aligned} f(\mathbf{b}) &= E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} = \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \\ &= \frac{1}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{y} + \frac{1}{n} \mathbf{y}^\top \mathbf{y} + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \end{aligned}$$

- Tính độ dốc:

$$\nabla f(\mathbf{b}) = \frac{2}{n} \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{X}^\top \mathbf{y} + \frac{2\lambda}{n} \mathbf{b}$$

Linear Regression - A New Minimization Solution

$$\begin{aligned} f(\mathbf{b}) &= E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} = \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \\ &= \frac{1}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{y} + \frac{1}{n} \mathbf{y}^\top \mathbf{y} + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \end{aligned}$$

- Compute the gradient:

$$\nabla f(\mathbf{b}) = \frac{2}{n} \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{X}^\top \mathbf{y} + \frac{2\lambda}{n} \mathbf{b}$$

- Setting $\nabla f(\mathbf{b})$ to $\mathbf{0}$, and solve for the **ridge regression** of \mathbf{b} :

$$\mathbf{X}^\top \mathbf{X} \mathbf{b} - \mathbf{X}^\top \mathbf{y} + \lambda \mathbf{b} = \mathbf{0}$$

$$\mathbf{b}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) = \mathbf{X}^\top \mathbf{y}$$

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

Hồi quy tuyến tính - Một giải pháp tối thiểu hóa mới

$$\begin{aligned} f(\mathbf{b}) &= E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} = \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \\ &= \frac{1}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{b}^\top \mathbf{X}^\top \mathbf{y} + \frac{1}{n} \mathbf{y}^\top \mathbf{y} + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \end{aligned}$$

- Tính độ dốc:

$$\nabla f(\mathbf{b}) = \frac{2}{n} \mathbf{X}^\top \mathbf{X} \mathbf{b} - \frac{2}{n} \mathbf{X}^\top \mathbf{y} + \frac{2\lambda}{n} \mathbf{b}$$


- Đặt $\nabla f(\mathbf{b})$ thành $\mathbf{0}$ và giải hồi quy sườn của \mathbf{b} :

$$\mathbf{X}^\top \mathbf{X} \mathbf{b} - \mathbf{X}^\top \mathbf{y} + \lambda \mathbf{b} = \mathbf{0}$$

$$\mathbf{b}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) = \mathbf{X}^\top \mathbf{y}$$

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$


Ridge Regression



ridge coefficients $\mathbf{b}_{RR} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$

- The optimal vector \mathbf{b} that minimizes $E(\mathbf{b})$ and satisfies the constraint will be on a contour of constant error.


Hồi quy sườn



hệ số sườn $\mathbf{b}_{RR} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$

- Vectơ \mathbf{b} tối ưu làm cực tiểu $E(\mathbf{b})$ và thỏa mãn ràng buộc sẽ nằm trên một đường bao có sai số không đổi.


Ridge Regression



ridge coefficients $\mathbf{b}_{RR} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$

- The optimal vector \mathbf{b} that minimizes $E(\mathbf{b})$ and satisfies the constraint will be on a contour of constant error.
- The above illustration shows that the direction of the optimal vector \mathbf{b} does not point in the direction of the OLS solution.

Hồi quy sườn



hệ số sườn $\mathbf{b}_{RR} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$

- Vectơ \mathbf{b} tối ưu làm cực tiểu $E(\mathbf{b})$ và thỏa mãn ràng buộc sẽ nằm trên một đường bao có sai số không đổi.
- Hình minh họa trên cho thấy hướng của vectơ \mathbf{b} không chỉ theo hướng của giải pháp OLS.

Ridge Regression

- If we set the hyperparameter $\lambda = 0$, the ridge solution is the same as the OLS solution.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

Hồi quy sườn

- Nếu chúng ta đặt siêu tham số $\lambda = 0$, giải pháp sườn giống như giải pháp OLS.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

Ridge Regression

- If we set the hyperparameter $\lambda = 0$, the ridge solution is the same as the OLS solution.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

- If λ becomes larger and larger, the terms on the diagonal of $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ will be dominated by such λ values.

Hồi quy sườn

- Nếu chúng ta đặt siêu tham số $\lambda = 0$, giải pháp sườn giống như giải pháp OLS.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

- Nếu λ ngày càng lớn thì các số hạng trên đường chéo của $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ sẽ bị chi phối bởi các giá trị λ đó.

Ridge Regression

- If we set the hyperparameter $\lambda = 0$, the ridge solution is the same as the OLS solution.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

- If λ becomes larger and larger, the terms on the diagonal of $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ will be dominated by such λ values.
- The matrix inverse, $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}$, will be dominated by the inverse of the terms on its diagonal:

$$\lambda \gg 0 \Rightarrow (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \rightarrow \frac{1}{\lambda} \mathbf{I}$$

$$\lambda \rightarrow \infty \Rightarrow (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \rightarrow \mathbf{0}_{(p,p)}$$

$$\lambda \rightarrow \infty \Rightarrow \mathbf{b}_{RR} = \mathbf{0}$$

Hồi quy sườn

- Nếu chúng ta đặt siêu tham số $\lambda = 0$, giải pháp sườn giống như giải pháp OLS.

$$\mathbf{b}_{RR} = (\mathbf{X}^\top \mathbf{X} + 0\mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{b}_{OLS}$$

- Nếu λ ngày càng lớn thì các số hạng trên đường chéo của $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ sẽ bị chi phối bởi các giá trị λ đó. sẽ bị chi
- Ma trận nghịch đảo, $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}$, phối bởi nghịch đảo của các điều khoản trên đường chéo của nó:

$$\lambda \gg 0 \Rightarrow (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \rightarrow \frac{1}{\lambda} \mathbf{I}$$

$$\lambda \rightarrow \infty \Rightarrow (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \rightarrow \mathbf{0}_{(p,p)}$$

$$\lambda \rightarrow \infty \Rightarrow \mathbf{b}_{RR} = \mathbf{0}$$

Ridge Regression - Relation between λ and c

- Our two minimization problems:

$$\min_{\mathbf{b}} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \right\}$$

Hồi quy sườn - Mối quan hệ giữa λ và c

- Hai vấn đề giảm thiểu của chúng tôi:

$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{N} \mathbf{b}^\top \mathbf{b} \right\}$$

Ridge Regression - Relation between λ and c

- Our two minimization problems:

$$\min_{\mathbf{b}} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \right\}$$

- Imposing a large budget constraint c causes λ to become smaller. The smaller the λ , the closer \mathbf{b}_{RR} to the OLS solution.

Hồi quy sườn - Mỗi quan hệ giữa λ và c

- Hai vấn đề giảm thiểu của chúng tôi:

$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{N} \mathbf{b}^\top \mathbf{b} \right\}$$

- Áp đặt một ràng buộc ngân sách lớn c làm cho λ trở nên nhỏ hơn. λ càng nhỏ, \mathbf{b}_{RR} càng gần nghiệm OLS.

Ridge Regression - Relation between λ and c

- Our two minimization problems:

$$\min_{\mathbf{b}} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{n} \mathbf{b}^\top \mathbf{b} \right\}$$

- Imposing a large budget constraint c causes λ to become smaller. The smaller the λ , the closer \mathbf{b}_{RR} to the OLS solution.
- Imposing a small budget constraint c causes λ to become larger. The larger the λ , the smaller the ridge coefficients.

$$\uparrow c \Rightarrow \downarrow \lambda$$

$$\downarrow c \Rightarrow \uparrow \lambda$$

Hồi quy sườn - Mỗi quan hệ giữa λ và c

- Hai vấn đề giảm thiểu của chúng tôi:

$$\min_{\mathbf{b}} \left\{ \frac{1}{N} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) \right\} \text{ st } \|\mathbf{b}\|_2^2 = \mathbf{b}^\top \mathbf{b} \leq c$$

$$\min_{\mathbf{b}} \left\{ E(\mathbf{b}) + \frac{\lambda}{N} \mathbf{b}^\top \mathbf{b} \right\}$$

- Áp đặt một ràng buộc ngân sách lớn c làm cho λ trở nên nhỏ hơn. λ càng nhỏ, \mathbf{b}_{RR} càng gần nghiệm OLS.
- Áp đặt một ràng buộc ngân sách nhỏ c làm cho λ trở nên lớn hơn. λ càng lớn thì hệ số sườn núi càng nhỏ.

$$\begin{matrix} c \\ \lambda \end{matrix} \quad \begin{matrix} c \\ \lambda \end{matrix}$$

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.
- Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(x_1, y_1), \dots, (x_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Each fold set \mathcal{D}_{fold-k} plays the role of an evaluation \mathcal{D}_{eval-k} . The corresponding K training sets:

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Mỗi tập hợp nếp gấp \mathcal{D}_{fold-k} đóng vai trò của một \mathcal{D}_{eval-k} đánh giá. Các tập huấn luyện K tương ứng:

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Each fold set \mathcal{D}_{fold-k} plays the role of an evaluation \mathcal{D}_{eval-k} . The corresponding K training sets:
 - $\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Mỗi tập hợp nếp gấp \mathcal{D}_{fold-k} đóng vai trò của một \mathcal{D}_{eval-k} đánh giá. K tập huấn luyện tương ứng:
 - $\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Each fold set \mathcal{D}_{fold-k} plays the role of an evaluation \mathcal{D}_{eval-k} . The corresponding K training sets:
 - $\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$
 - $\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Mỗi tập hợp nếp gấp \mathcal{D}_{fold-k} đóng vai trò của một \mathcal{D}_{eval-k} đánh giá. K tập huấn luyện tương ứng:

$$\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$$

$$\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$$

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Each fold set \mathcal{D}_{fold-k} plays the role of an evaluation \mathcal{D}_{eval-k} . The corresponding K training sets:
 - $\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$
 - $\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$
 - ...

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Mỗi tập hợp nếp gấp \mathcal{D}_{fold-k} đóng vai trò của một \mathcal{D}_{eval-k} đánh giá. K tập huấn luyện tương ứng:

$$\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$$

$$\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$$

...

Ridge Regression - How to find λ ?

- In ridge regression, λ is a hyperparameter that we need to tune.
- We randomly split the training data:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

into K folds:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Each fold set \mathcal{D}_{fold-k} plays the role of an evaluation \mathcal{D}_{eval-k} . The corresponding K training sets:
 - $\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$
 - $\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$
 - \dots
 - $\mathcal{D}_{train-K} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-K}$

Hồi quy sườn - Cách tìm λ ?

- Trong hồi quy sườn núi, λ là một siêu tham số mà chúng ta cần điều chỉnh.

Chúng tôi chia ngẫu nhiên dữ liệu huấn luyện:

$$\mathcal{D}_{train} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$$

thành K nếp gấp:

$$\mathcal{D}_{train} = \mathcal{D}_{fold-1} \cup \mathcal{D}_{fold-2} \cup \dots \cup \mathcal{D}_{fold-K}$$

- Mỗi tập hợp nếp gấp \mathcal{D}_{fold-k} đóng vai trò của một \mathcal{D}_{eval-k} đánh giá. K tập huấn luyện tương ứng:

$$\mathcal{D}_{train-1} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-1}$$

$$\mathcal{D}_{train-2} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-2}$$

$$\dots$$

$$\mathcal{D}_{train-K} = \mathcal{D}_{train} \setminus \mathcal{D}_{fold-K}$$

Ridge Regression - How to find λ ?

1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:

Machine Translated by Google

Hồi quy sườn - Cách tìm λ ?

1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:
 - Fit RR model $h_{b,k}$ with λ_b on $\mathcal{D}_{train-k}$

Machine Translated by Google

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:
 - Khớp mô hình RR $h_{b,k}$ với λ_b trên $\mathcal{D}_{train-k}$

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:
 - Fit RR model $h_{b,k}$ with λ_b on $\mathcal{D}_{train-k}$
 - Compute and store $E_{eval-k}(h_{b,k})$ using \mathcal{D}_{eval-k}

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:
 - Khớp mô hình RR $h_{b,k}$ với λ_b trên $\mathcal{D}_{train-k}$
 - Tính toán và lưu trữ $E_{eval-k}(h_{b,k})$ bằng \mathcal{D}_{eval-k}

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:
 - Fit RR model $h_{b,k}$ with λ_b on $\mathcal{D}_{train-k}$
 - Compute and store $E_{eval-k}(h_{b,k})$ using \mathcal{D}_{eval-k}
 - Compute and store $E_{cvb} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:
 - Khớp mô hình RR $h_{b,k}$ với λ_b trên $\mathcal{D}_{train-k}$
 - Tính toán và lưu trữ $E_{eval-k}(h_{b,k})$ bằng \mathcal{D}_{eval-k}
 - Tính toán và lưu trữ $E_{cvb} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:
 - Fit RR model $h_{b,k}$ with λ_b on $\mathcal{D}_{train-k}$
 - Compute and store $E_{eval-k}(h_{b,k})$ using \mathcal{D}_{eval-k}
 - Compute and store $E_{cv_b} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$
- 2 Compute all cross validation errors $E_{cv_1}, E_{cv_2}, \dots, E_{cv_B}$ and choose the smallest $E_{cv_{b^*}}$.

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:
 - Khớp mô hình RR $h_{b,k}$ với λ_b trên $\mathcal{D}_{train-k}$
 - Tính toán và lưu trữ $E_{eval-k}(h_{b,k})$ bằng \mathcal{D}_{eval-k}
 - Tính toán và lưu trữ $E_{cv_b} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$
- 2 Tính toán tất cả các lỗi xác thực chéo $E_{cv_1}, E_{cv_2}, \dots, E_{cv_B}$ và chọn $E_{cv_{b^*}}$ nhỏ nhất.

Ridge Regression - How to find λ ?

- 1 For $\lambda_b = 0.001, 0.002, \dots, \lambda_B$:
 - For $k = 1, \dots, K$:
 - Fit RR model $h_{b,k}$ with λ_b on $\mathcal{D}_{train-k}$
 - Compute and store $E_{eval-k}(h_{b,k})$ using \mathcal{D}_{eval-k}
 - Compute and store $E_{cv_b} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$
- 2 Compute all cross validation errors $E_{cv_1}, E_{cv_2}, \dots, E_{cv_B}$ and choose the smallest $E_{cv_{b^*}}$.
- 3 Use λ^* to fit the final Ridge Regression model:

$$\hat{\mathbf{y}} = (\mathbf{X}^T \mathbf{X} + \lambda^* \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

Hồi quy sườn - Cách tìm λ ?

- 1 Với $\lambda_b = 0,001, 0,002, \dots, \lambda_B$:
 - Với $k = 1, \dots, K$:
 - Khớp mô hình RR $h_{b,k}$ với λ_b trên $\mathcal{D}_{train-k}$
 - Tính toán và lưu trữ $E_{eval-k}(h_{b,k})$ bằng \mathcal{D}_{eval-k}
 - Tính toán và lưu trữ $E_{cv_b} = \frac{1}{K} \sum_k E_{eval-k}(h_{b,k})$
- 2 Tính toán tất cả các lỗi xác thực chéo $E_{cv_1}, E_{cv_2}, \dots, E_{cv_B}$ và chọn $E_{cv_{b^*}}$ nhỏ nhất.
- 3 Sử dụng λ để phù hợp với mô hình Hồi quy sườn cuối cùng:

$$\hat{\mathbf{y}} = (\mathbf{X}^T \mathbf{X} + \lambda^* \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

Least Absolute Shrinkage and Selection Operator - LASSO

- Instead of using L_2 norm as in Ridge Regression:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_2^2 \leq c$$

Toán tử lựa chọn và co rút tuyệt đối nhỏ nhất - LASSO

- Thay vì sử dụng định mức L_2 như trong Hồi quy độ dốc:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_2^2 \leq c$$

Least Absolute Shrinkage and Selection Operator - LASSO

- Instead of using L_2 norm as in Ridge Regression:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_2^2 \leq c$$

- We use L_1 norm:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_1 \leq c$$

Toán tử lựa chọn và co rút tuyệt đối nhỏ nhất - LASSO

- Thay vì sử dụng định mức L_2 như trong Hồi quy độ dốc:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_2^2 \leq c$$

- Ta sử dụng định mức L_1 :

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_1 \leq c$$

Least Absolute Shrinkage and Selection Operator - LASSO

- Instead of using L_2 norm as in Ridge Regression:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_2^2 \leq c$$

- We use L_1 norm:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_1 \leq c$$

- The L_1 norm constraint is:

$$\|\mathbf{b}\|_1 \leq c \iff \sum_{j=1}^p |b_j| \leq c$$

Toán tử lựa chọn và co rút tuyệt đối nhỏ nhất - LASSO

- Thay vì sử dụng định mức L_2 như trong Hồi quy độ dốc:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_2^2 \leq c$$

- Ta sử dụng định mức L_1 :

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_1 \leq c$$

- Ràng buộc định mức L_1 là:

$$\|\mathbf{b}\|_1 \leq c \iff \sum_{j=1}^p |b_j| \leq c$$

Least Absolute Shrinkage and Selection Operator - LASSO

- Instead of using L_2 norm as in Ridge Regression:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_2^2 \leq c$$

- We use L_1 norm:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{subject to} \quad \|\mathbf{b}\|_1 \leq c$$

- The L_1 norm constraint is:

$$\|\mathbf{b}\|_1 \leq c \iff \sum_{j=1}^p |b_j| \leq c$$

- Our minimization problem then becomes:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \lambda \sum_{j=1}^p |b_j| \right\}$$

Toán tử lựa chọn và co rút tuyệt đối nhỏ nhất - LASSO

- Thay vì sử dụng định mức L_2 như trong Hồi quy độ dốc:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_2^2 \leq c$$

- Ta sử dụng định mức L_1 :

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} \|\mathbf{X}\mathbf{b} - \mathbf{y}\|_2^2 \right\} \quad \text{theo} \quad \|\mathbf{b}\|_1 \leq c$$


- Ràng buộc định mức L_1 là:

$$\|\mathbf{b}\|_1 \leq c \iff \sum_{j=1}^p |b_j| \leq c$$

- Khi đó bài toán tối thiểu hóa của chúng ta trở thành:

$$\min_{\mathbf{b} \in \mathbb{R}^p} \left\{ \frac{1}{n} (\mathbf{X}\mathbf{b} - \mathbf{y})^\top (\mathbf{X}\mathbf{b} - \mathbf{y}) + \lambda \sum_{j=1}^p |b_j| \right\}$$


LASSO - Variable Selection



- The ideal point has b_1 coordinate equal to 0.
- LASSO completely zero-ed out b_1 in the model, reducing the number of coefficients from 2 down to 1.

Machine Translated by Google

LASSO - Lựa chọn biến



- Điểm lý tưởng có tọa độ b_1 bằng 0.
- LASSO loại bỏ hoàn toàn b_1 trong mô hình, giảm số hệ số từ 2 xuống còn 1.